Modelos matemáticos de enfermedades infecciosas con Python

Clase 3: Cuantificando la incertidumbre con Bayes

Maria Luisa Daza Torres

Escuela de Invierno, 2026

Noviembre 5, 2026



Instituto de Matemáticas
Unidad Cuernavaca

De la clase anterior a la pregunta de hoy

En la clase anterior **ajustamos la transmisión** del SIR a los casos observados, por mínimos cuadrados.

$$\underbrace{\beta}_{\text{parámetro}} \longrightarrow \underbrace{G_j(\beta)}_{\text{incidencia SIR}} \longleftrightarrow \underbrace{y_j}_{\text{casos observados}} \longrightarrow \underbrace{\widehat{\beta}}_{\text{estimación}} .$$

El **bootstrap** nos permitió estudiar la variabilidad de $\widehat{\beta}$ al repetir, de manera simulada, el proceso de observación bajo el modelo ajustado.

La nueva pregunta

Dados los casos que ya observamos, ¿qué valores de β son plausibles **y con qué probabilidad posterior**?

Hoy buscamos $p(\beta \mid \mathbf{y})$, $\qquad \mathbf{y} = (y_1, \ldots, y_m)$.

Una estimación puntual no cuenta toda la historia

El ajuste puede dar, por ejemplo,

$$\boxed{\widehat{\beta} = 0{,}36 \text{ día}^{-1}.}$$

Esto resume el ajuste, pero no dice por sí solo:

- ¿Qué tan concentrada está la evidencia alrededor de 0,36?
- ¿Son también plausibles $\beta = 0{,}33$ o $\beta = 0{,}39$?
- ¿Cuánto cambian las trayectorias futuras si cambia β?

Pasaremos de un valor estimado a una distribución de valores plausibles.

¿Para qué cuantificar la incertidumbre?

En una epidemia, los casos futuros no se conocen con exactitud. Esta incertidumbre afecta:

- la preparación de servicios de salud;
- la vigilancia epidemiológica;
- la evaluación de intervenciones;
- la probabilidad de superar un umbral de incidencia.

Una diferencia importante

Dos pronósticos pueden tener el **mismo número esperado de casos**, pero **distinta incertidumbre**. No deberían interpretarse de la misma manera.

Del SIR a los casos observados

El modelo SIR describe los estados $S(t)$, $I(t)$ y $R(t)$, que no necesariamente se observan de forma directa.

$$\frac{dS}{dt} = -\beta \frac{SI}{N}, \qquad \frac{dI}{dt} = \beta \frac{SI}{N} - \gamma I, \qquad \frac{dR}{dt} = \gamma I.$$

Para cada valor de β, la **incidencia acumulada en el día** j es

$$\boxed{G_j(\beta) = S(j-1;\beta) - S(j;\beta).}$$

Los datos son Y_j, los casos registrados durante ese día.

$$\boxed{\beta \longrightarrow (S, I, R) \longrightarrow G_j(\beta) \longrightarrow Y_j.}$$

El último paso requiere un **modelo de observación**: los datos no tienen por qué coincidir exactamente con el SIR.

¿De dónde proviene la incertidumbre?

1. **Parámetros.** La tasa β es desconocida. En un análisis más completo también lo serían γ, las condiciones iniciales u otros parámetros.

2. **Observación.**

   Los casos registrados fluctúan alrededor de la incidencia esperada y pueden estar sujetos a errores de reporte.

3. **Especificación.**

   El SIR simplifica los contactos, la población y la evolución del brote.

Qué haremos en esta clase

Representaremos la incertidumbre sobre β y la variación de las observaciones, **condicionando en las demás cantidades conocidas o fijadas**.

Bayes: aprender a partir de los datos



- **A priori:** qué valores de β consideramos posibles antes de analizar esta serie.
- **Verosimilitud:** qué tan bien explicaría cada valor de β los casos observados.
- **Posterior:** cómo cambia nuestra incertidumbre después de ver los datos.

El teorema de Bayes

Para un parámetro θ y datos $\mathbf{y}$:

$$p(\theta \mid \mathbf{y}) = \frac{\overbrace{p(\mathbf{y} \mid \theta)}^{\text{verosimilitud}} \overbrace{p(\theta)}^{\text{a priori}}}{\underbrace{p(\mathbf{y})}_{\text{normalizador}}}.$$

El denominador es

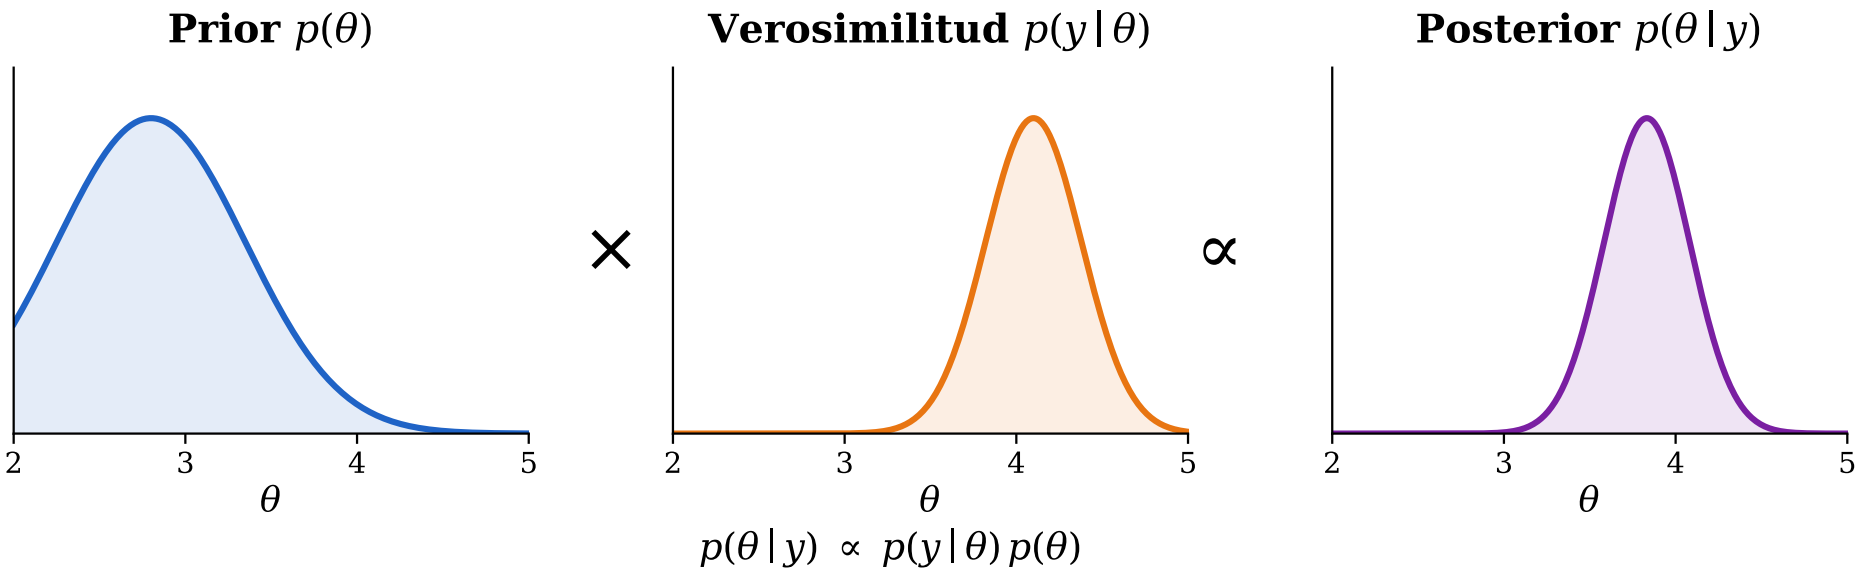
$$p(\mathbf{y}) = \int p(\mathbf{y} \mid \theta) p(\theta)\, d\theta.$$

Como **no depende de** θ, podemos escribir

$$p(\theta \mid \mathbf{y}) \propto p(\mathbf{y} \mid \theta) p(\theta).$$

La información previa se actualiza con la evidencia de los datos.

Prior, verosimilitud y posterior



- **Prior** representa nuestro conocimiento sobre θ antes de observar los nuevos datos.
- **Verosimilitud** relaciona los datos observados con los posibles valores de θ.
- **Posterior** combina la información previa con la información contenida en los datos.

La posterior es una distribución, no un número

La inferencia Bayesiana proporciona una distribución para los parámetros desconocidos:

$$p(\theta \mid y).$$

A partir de ella podemos obtener:

- estimaciones puntuales, por ejemplo

$$\mathbb{E}[\theta \mid y];$$

- intervalos de probabilidad;
- probabilidades sobre los parámetros;
- predicciones de observaciones futuras.

La incertidumbre forma parte del resultado de la inferencia.

¿Qué nos proporciona una distribución posterior?

En nuestro caso, una vez que conocemos $p(\beta \mid \mathbf{y})$ podemos calcular:

- una **media o mediana posterior** para β;
- un **intervalo creíble** que contenga, por ejemplo, el 90 % de la probabilidad posterior;
- probabilidades como $\mathbb{P}(\beta > \gamma \mid \mathbf{y})$;
- posibles trayectorias futuras del brote.

Interpretación

Un intervalo creíble al 90 % contiene el 90 % de la probabilidad **posterior**, dadas las observaciones, la a priori y el modelo.

Volvamos al SIR: ¿qué debemos especificar?

Queremos calcular

$$p(\beta \mid \mathbf{y}).$$

1. Modelo de observación

Determina la **verosimilitud**:

$$L(\beta; \mathbf{y}) = p(\mathbf{y} \mid \beta).$$

¿Cómo se relacionan los casos observados con $G_j(\beta)$?

2. Información previa

Determina la **a priori**:

$$p(\beta).$$

¿Qué valores de transmisión consideramos plausibles antes de analizar los datos?

$$\underbrace{L(\beta; \mathbf{y})}_{\text{datos}} \times \underbrace{p(\beta)}_{\text{conocimiento previo}} \longrightarrow \underbrace{p(\beta \mid \mathbf{y})}_{\text{posterior}}.$$

1. El modelo de observación de la clase anterior

Conservamos el **modelo gaussiano** utilizado en el ajuste por mínimos cuadrados:

$$\boxed{Y_j \mid \beta, \widehat{\sigma} \sim \mathcal{N}\left(G_j(\beta), \widehat{\sigma}^2\right), \quad j = 1, \ldots, m.}$$

- $G_j(\beta)$: incidencia diaria prevista por el SIR.
- Y_j: casos registrados durante el día j.
- $\widehat{\sigma}$: desviación estándar del error, fijada para esta clase.

Supondremos **errores independientes** entre días, condicionando en β.

También fijamos γ, N y las condiciones iniciales. El modelo normal es una aproximación: admite valores negativos, a diferencia de los recuentos reales.

2. Del modelo de observación a la verosimilitud

Para un solo día:

$$p(y_j \mid \beta, \widehat{\sigma}) = \frac{1}{\sqrt{2\pi}\widehat{\sigma}} \exp\left[-\frac{(y_j - G_j(\beta))^2}{2\widehat{\sigma}^2}\right].$$

Para los m días, si son condicionalmente independientes:

$$\boxed{L(\beta; \mathbf{y}) = \prod_{j=1}^{m} \frac{1}{\sqrt{2\pi}\widehat{\sigma}} \exp\left[-\frac{(y_j - G_j(\beta))^2}{2\widehat{\sigma}^2}\right].}$$

Para cada candidato β, resolvemos el SIR, calculamos $G_j(\beta)$ y evaluamos qué tan compatibles son los datos.

¿Por qué mínimos cuadrados y máxima verosimilitud coinciden?

En la clase anterior minimizamos

$$Q(\beta) = \sum_{j=1}^{m} [y_j - G_j(\beta)]^2 .$$

Al tomar el logaritmo de la verosimilitud gaussiana:

$$\boxed{\log L(\beta; \mathbf{y}) = -\frac{m}{2} \log(2\pi\widehat{\sigma}^2) - \frac{1}{2\widehat{\sigma}^2} Q(\beta).}$$

Como $\widehat{\sigma}$ se mantiene fijo, el primer término es constante:

$$\boxed{\arg\max_{\beta>0} L(\beta; \mathbf{y}) = \arg\min_{\beta>0} Q(\beta).}$$

Conexión con la clase anterior

El ajuste por mínimos cuadrados ya estaba asociado a un **modelo probabilístico de observación**. Ahora agregamos la a priori.

3. Elegir una a priori para β

Antes de ver esta serie, podemos utilizar conocimiento epidemiológico:

- la tasa de transmisión es **positiva**;
- estudios previos pueden sugerir escalas plausibles;
- la a priori debe expresarse en las unidades de β (día^{-1}).

Una opción es una **distribución lognormal**:

$$\boxed{\log \beta \sim \mathcal{N}(\mu_\beta, \tau_\beta^2).}$$

Por ejemplo, como elección *ilustrativa*:

$$\mu_\beta = \log(0{,}35), \qquad \tau_\beta = 0{,}35.$$

La a priori no es un dato observado: es una suposición explícita que debemos justificar y examinar.

¿Qué representa esa a priori?

Si

$$\log \beta \sim \mathcal{N}(\mu_\beta, \tau_\beta^2),$$

entonces

$$\boxed{p(\beta) = \frac{1}{\beta \tau_\beta \sqrt{2\pi}} \exp\left[-\frac{(\log \beta - \mu_\beta)^2}{2\tau_\beta^2}\right], \qquad \beta > 0.}$$

- μ_β determina el centro **en escala logarítmica**.
- τ_β controla cuán dispersos consideramos los valores posibles.
- La distribución asigna probabilidad solamente a $\beta > 0$.

Pregunta para el grupo

¿Qué sucedería si usáramos una a priori mucho más concentrada?
¿Y si tuviéramos muy pocos días de datos?

4. Construir la distribución posterior

Aplicamos Bayes con el **mismo modelo gaussiano** y la a priori lognormal:

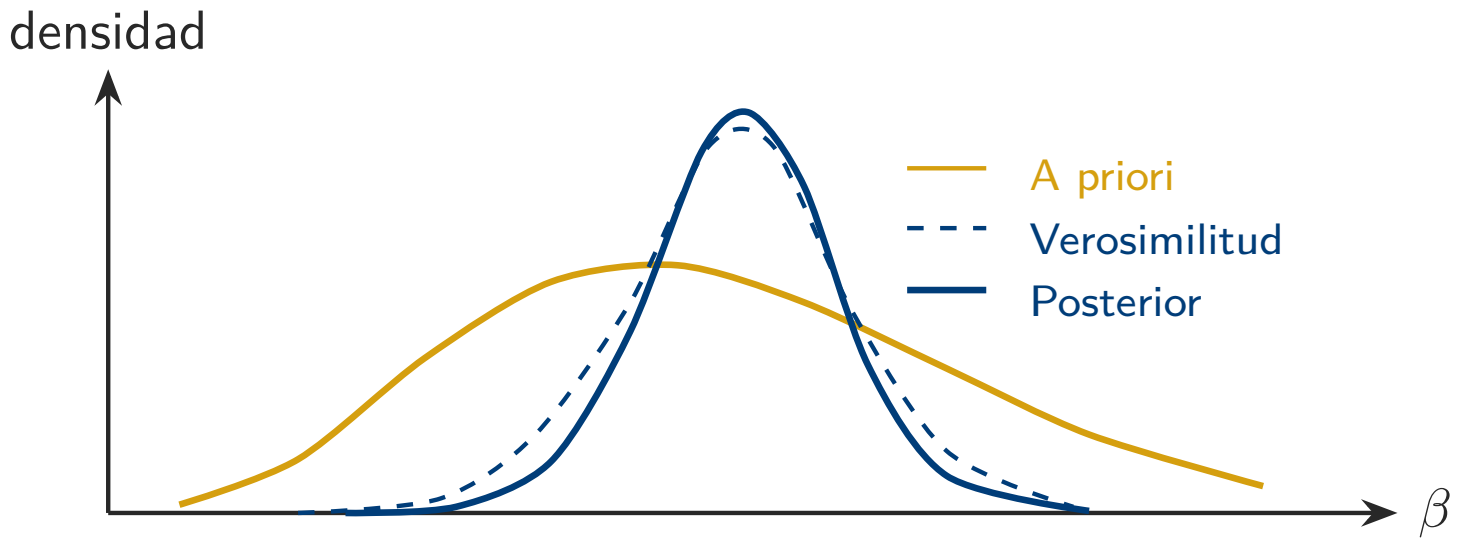
$$p(\beta \mid \mathbf{y}) = \frac{L(\beta; \mathbf{y}) p(\beta)}{\int_0^\infty L(b; \mathbf{y}) p(b)\, db}.$$

Por lo tanto,

$$p(\beta \mid \mathbf{y}) \propto \exp\left[-\frac{Q(\beta)}{2\widehat{\sigma}^2}\right] \times \frac{1}{\beta} \exp\left[-\frac{(\log \beta - \mu_\beta)^2}{2\tau_\beta^2}\right], \quad \beta > 0.$$

La posterior favorece los valores de β compatibles tanto con los datos como con la información previa.

De la a priori a la posterior: ¿qué cambia?



La verosimilitud se ha reescalado para comparar las formas.

La posterior responde preguntas epidemiológicas

Una vez obtenida $p(\beta \mid \mathbf{y})$, podemos reportar:

- la mediana posterior de β;
- un intervalo creíble de 90 % para β;
- la probabilidad posterior de que la transmisión supere un umbral.

Si γ es conocido y el SIR tiene transmisión homogénea,

$$\boxed{R_0 = \frac{\beta}{\gamma}.}$$

Así, para $\gamma > 0$ fijo:

$$\boxed{\mathbb{P}(R_0 > 1 \mid \mathbf{y}) = \mathbb{P}(\beta > \gamma \mid \mathbf{y}).}$$

Aprender sobre β también nos permite aprender sobre R_0.

Ya construimos la posterior. ¿Cómo la calculamos?

Para el SIR, con γ, las condiciones iniciales y $\widehat{\sigma}$ fijos, obtuvimos

$$\boxed{\pi(\beta) = p(\beta \mid \mathbf{y}) \propto L(\beta; \mathbf{y}) p(\beta), \qquad \beta > 0.}$$

1. **Solución analítica:** posible para algunos modelos conjugados.
2. **Cuadrícula e integración numérica:** factible con un solo parámetro.
3. **cadenas de Monte Carlo:** aproximar integrales usando muestras de la posterior.

Nuestra pregunta computacional

¿Cómo generamos valores de β que representen correctamente su distribución posterior?

De una integral a un promedio

Por ejemplo, queremos calcular la media posterior:

$$\mathbb{E}[\beta \mid \mathbf{y}] = \int_0^\infty \beta\, \pi(\beta)\, d\beta.$$

Si disponemos de muestras representativas $\beta^{(1)}, \ldots, \beta^{(M)}$, aproximamos

$$\boxed{\mathbb{E}[\beta \mid \mathbf{y}] \approx \frac{1}{M} \sum_{s=1}^{M} \beta^{(s)}.}$$

Con γ conocido, también podemos estimar

$$\mathbb{P}(R_0 > 1 \mid \mathbf{y}) \approx \frac{1}{M} \sum_{s=1}^{M} \mathbf{1}\{\beta^{(s)} > \gamma\}.$$

La simulación transforma integrales difíciles en promedios.

MCMC: visitar la posterior mediante una cadena

La idea

En lugar de generar observaciones independientes, construimos una **cadena de Markov** cuyo recorrido, a largo plazo, representa la distribución que queremos estudiar.

$$\boxed{\beta^{(0)} \longrightarrow \beta^{(1)} \longrightarrow \cdots \longrightarrow \beta^{(M)}.}$$

- **Markov:** el siguiente valor depende del estado actual, no de toda la historia.
- **Monte Carlo:** usamos los valores visitados para estimar medias, intervalos y probabilidades posteriores.
- Las muestras suelen estar **correlacionadas**.

Debemos diseñar bien la regla que mueve la cadena.

¿Qué propiedades buscamos en una cadena MCMC?

1. **Irreducibilidad:** la cadena puede alcanzar las regiones con probabilidad positiva de la posterior.
2. **Aperiodicidad:** no queda obligada a recorrer los estados en ciclos de periodo fijo.
3. **Recurrencia positiva de Harris:** vuelve a las regiones relevantes con la frecuencia adecuada.

Bajo las condiciones habituales de convergencia, estas propiedades permiten justificar promedios como

$$\frac{1}{M}\sum_{s=1}^{M} f(\beta^{(s)}) \longrightarrow \mathbb{E}_{\pi}[f(\beta)].$$

Una cadena útil debe explorar la posterior, no solo moverse.

Metropolis–Hastings: proponer, comparar y decidir

Partimos de un valor actual $\beta^{(k)} > 0$.

1. **Proponer** un candidato cercano:

$$\boxed{\beta^* = \beta^{(k)} + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, s_q^2).}$$

2. **Comparar** cuánto favorece la posterior al candidato frente al valor actual.
3. **Aceptar o rechazar** el movimiento: si lo rechazamos, repetimos el estado actual.

Intuición

Siempre aceptamos un candidato con mayor densidad posterior; uno con menor densidad todavía puede aceptarse.

La regla de aceptación de Metropolis–Hastings

En general, con una propuesta $q(\beta^* \mid \beta)$,

$$\boxed{\alpha(\beta, \beta^*) = \text{mín}\left\{1, \frac{\pi(\beta^*)q(\beta \mid \beta^*)}{\pi(\beta)q(\beta^* \mid \beta)}\right\}.}$$

Como nuestra propuesta normal es **simétrica**, se simplifica a

$$\boxed{\alpha = \text{mín}\left\{1, \frac{L(\beta^*; \mathbf{y})p(\beta^*)}{L(\beta^{(k)}; \mathbf{y})p(\beta^{(k)})}\right\}.}$$

Simulamos $u \sim \text{Uniforme}(0, 1)$: aceptamos si $u < \alpha$; en otro caso conservamos $\beta^{(k)}$.

La dificultad de caminar al azar

Saltos pequeños

Se aceptan con frecuencia, pero la cadena puede avanzar muy lentamente.

Saltos grandes

Intentan avanzar más lejos, pero pueden ser rechazados con frecuencia.

En problemas con varios parámetros, por ejemplo $(\beta, \gamma, I_0, \sigma)$, la posterior puede formar **regiones alargadas o curvas**.

¿Y si, en lugar de proponer saltos al azar, aprovecháramos la forma de la posterior para movernos?

Hamiltonian Monte Carlo: una idea diferente

¿Por qué ir más allá de una caminata aleatoria?

En MH con caminata aleatoria, las propuestas no utilizan la dirección en la que cambia la densidad posterior. En problemas con varios parámetros, esto puede hacer lenta la exploración.

La idea de HMC

Construir una propuesta mediante una **trayectoria dirigida** por el gradiente de la log-posterior, utilizando una **dinámica hamiltoniana auxiliar**.

No cambia la posterior: cambia la manera de construir propuestas.

El sistema hamiltoniano detrás de HMC

Sea $q \in \mathbb{R}^d$ el vector de coordenadas de los parámetros (sin restricciones), con densidad posterior $\pi(q)$. Agregamos un momento auxiliar $p \sim \mathcal{N}(0, M)$.

$$\underbrace{U(q) = -\log \pi(q)}_{\text{energía potencial}}, \qquad \underbrace{K(p) = \tfrac{1}{2} p^\top M^{-1} p}_{\text{energía cinética}}.$$

Definimos el **Hamiltoniano**:

$$\boxed{H(q, p) = U(q) + K(p).}$$

La trayectoria sigue las **ecuaciones de Hamilton**:

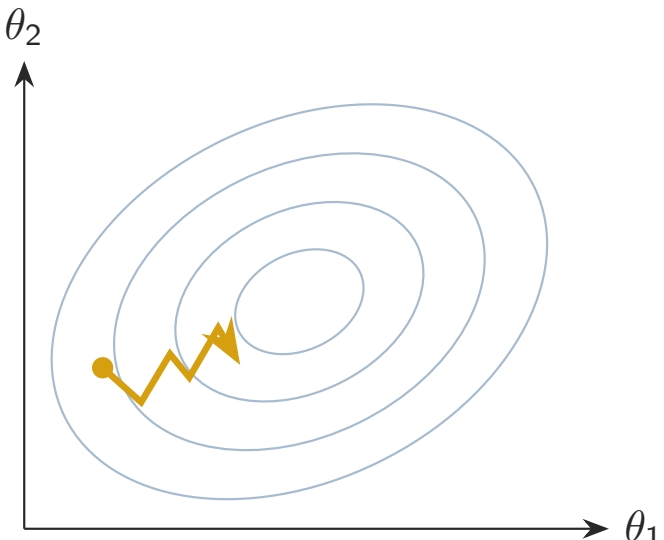
$$\boxed{\frac{dq}{ds} = \frac{\partial H}{\partial p} = M^{-1} p, \qquad \frac{dp}{ds} = -\frac{\partial H}{\partial q} = -\nabla U(q).}$$

¿Cómo se utiliza el sistema para generar muestras?

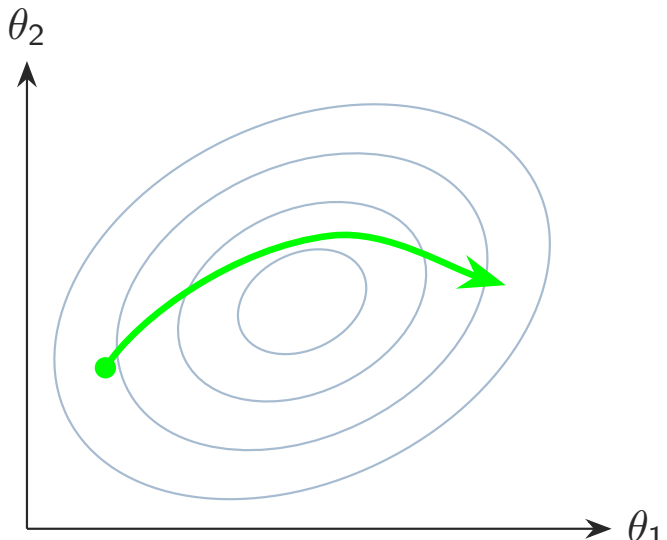
1. Partimos de la posición actual $q^{(k)}$.
2. Generamos un nuevo **momento** $p \sim \mathcal{N}(0, M)$.
3. Integramos numéricamente las ecuaciones hamiltonianas (por ejemplo, con *leapfrog*) durante varios pasos.
4. El punto final (q^*, p^*) define una **propuesta**.
5. Aceptamos la nueva posición con probabilidad

$$\boxed{\alpha_{\mathrm{HMC}} = \min\left\{1, \exp\left(H(q^{(k)}, p) - H(q^*, p^*)\right)\right\}.}$$

Una imagen para entender el movimiento



Metropolis–Hastings:
pequeños saltos propuestos



HMC: propuesta mediante
una trayectoria dirigida

Dos formas de explorar la misma posterior

	MH con caminata aleatoria	**HMC**
Propuesta	Salto aleatorio	Trayectoria guiada por gradientes
Información	Densidad posterior	Densidad y gradiente
Fortaleza	Simple de implementar	Puede explorar eficientemente geometrías complejas
Costo	Evaluaciones de densidad	Gradientes e integración numérica

Volviendo al modelo SIR

Para **un solo parámetro** β, una cuadrícula o MH pueden ser suficientes. HMC es especialmente interesante si queremos inferir conjuntamente $(\beta, \gamma, I_0, \sigma)$ y sus dependencias.

De las muestras posteriores a trayectorias SIR

Cualquiera de los métodos nos puede proporcionar muestras de la posterior:

$$\beta^{(1)}, \ldots, \beta^{(M)} \quad \text{representativas de } p(\beta \mid \mathbf{y}).$$

Para cada $\beta^{(s)}$ resolvemos el **mismo SIR**:

$$\boxed{\beta^{(s)} \longrightarrow (S^{(s)}, I^{(s)}, R^{(s)}) \longrightarrow G^{(s)}_{m+1:m+h\cdot}}$$

La nube de curvas describe la incertidumbre en la **incidencia media** prevista por el modelo.

El algoritmo de muestreo cambia; el modelo epidemiológico no.

Incidencia media no es lo mismo que casos futuros

Las curvas $G_j^{(s)} = G_j(\beta^{(s)})$ incorporan **incertidumbre en** β. Para predecir una observación futura añadimos el **error de observación** del mismo modelo gaussiano:

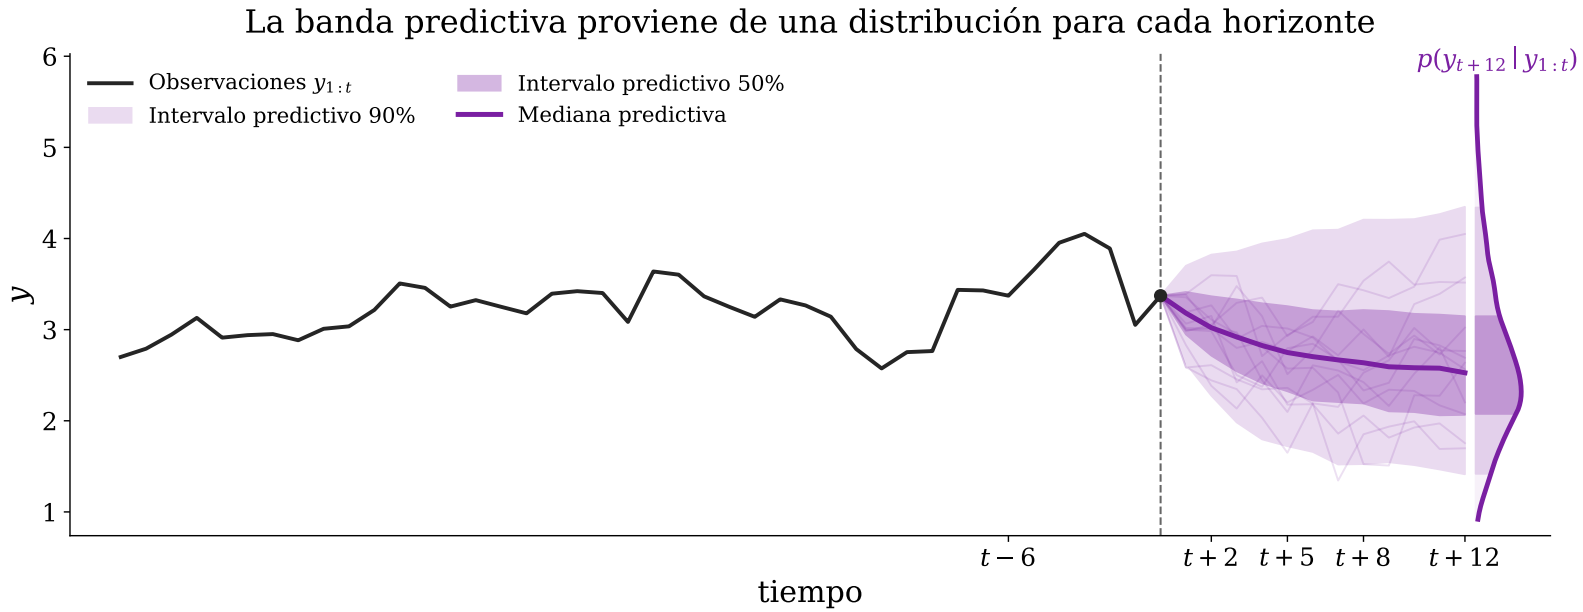
$$\boxed{\widetilde{Y}_j^{(s)} \sim \mathcal{N}\Big(G_j(\beta^{(s)}), \widehat{\sigma}^2\Big), \qquad j > m.}$$

Por ello,

$$\boxed{\text{banda para } G_j \quad \neq \quad \text{intervalo predictivo para } \widetilde{Y}_j.}$$

El modelo normal es una aproximación didáctica; para recuentos reales puede preferirse Poisson o binomial negativa.

Interpretación de la distribución predictiva



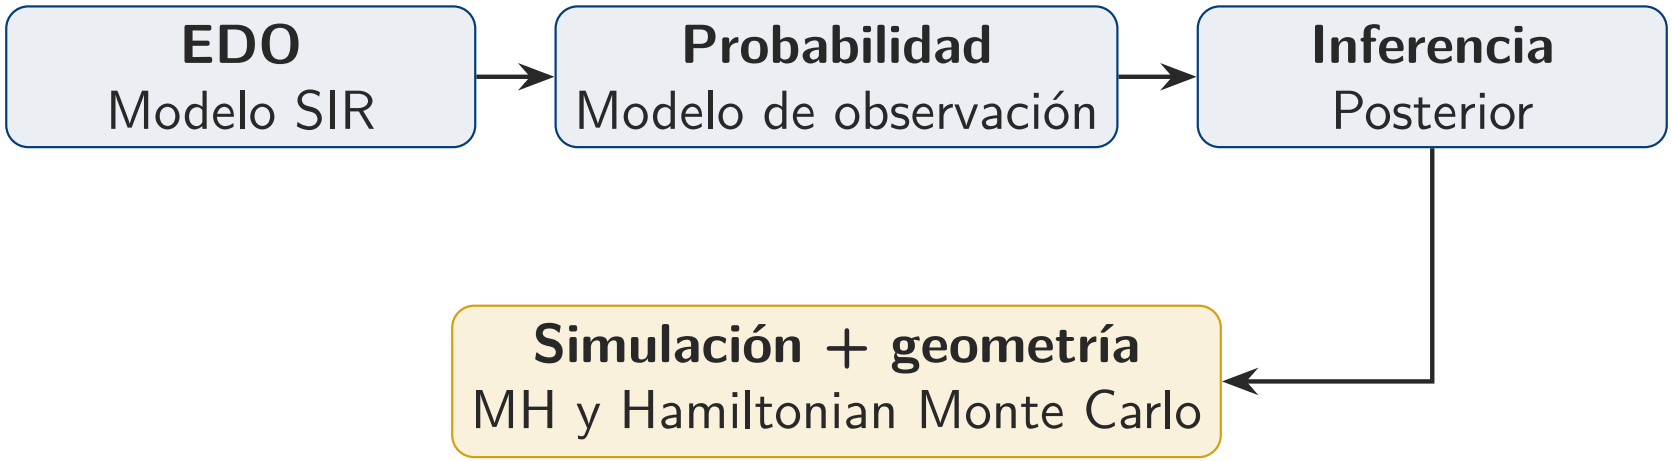
La predicción no es solamente un valor $\widehat{y}_{t+1}$, sino una distribución:

$$\boxed{p(y_{t+1} \mid y_{1:t}).}$$

Esta distribución describe los posibles valores futuros y la incertidumbre asociada a ellos.

Una predicción probabilística describe qué puede ocurrir y con qué incertidumbre.

Una misma idea, varias áreas de las matemáticas



Idea final

No buscamos solo una curva que ajuste los datos: queremos comprender qué podemos aprender de ellos, con cuánta incertidumbre, y qué escenarios produce el modelo.

Gracias

Preguntas y comentarios